

基于激光点云的智能挖掘机目标识别

朱建新¹, 沈东羽¹, 吴 钊²

(1. 中南大学 机电工程学院, 长沙 410083; 2. 山河智能装备股份有限公司, 长沙 410100)

摘 要: 传统智能工程机械的环境目标识别方法为单目或双目视觉识别, 识别速度慢、效率低且工况适应能力差。为进一步提升挖掘机的环境目标识别能力, 提出一种基于点云聚类特征直方图的目标识别方法。对原始点云进行滤波预处理, 通过聚类分离取得单个识别聚类, 建立待识别聚类的点云特征直方图, 在模型库中采用近邻搜索算法获得 k 个近邻, 并根据其匹配度得到最终识别结果。实验结果表明, 该方法针对挖掘机作业工况目标识别有较强的稳健性, 能在复杂工况下识别出多个目标且识别率高。

关键词: 智能挖掘机; 激光扫描; 点云数据; 特征直方图; 目标识别

中文引用格式: 朱建新, 沈东羽, 吴 钊. 基于激光点云的智能挖掘机目标识别[J]. 计算机工程, 2017, 43(1): 297-302.

英文引用格式: Zhu Jianxin, Shen Dongyu, Wu Kang. Target Recognition for Intelligent Excavator Based on Laser Point Cloud [J]. Computer Engineering, 2017, 43(1): 297-302.

Target Recognition for Intelligent Excavator Based on Laser Point Cloud

ZHU Jianxin¹, SHEN Dongyu¹, WU Kang²

(1. College of Mechanical and Electrical Engineering, Central South University, Changsha 410083, China;

2. Sunward Intelligent Equipment Co., Ltd., Changsha 410100, China)

【Abstract】 Traditional intelligent engineering machinery uses monocular or binocular recognition for environmental target recognition, which is inefficient and has low recognition rate and poor adaptation to the environment. A target recognition method based on point cloud clustering feature histogram is proposed in order to improve the ability of environmental target recognition for the excavator. After processing the raw point cloud data by filtering algorithm, the data is split into several single clusters using clustering algorithm. Point cloud characteristics histogram of be recognized cluster is built. In the model library k neighbor is got by using neighbor search algorithm, and the final recognition result is got according to matching degree. The experimental results show that the method works with strong robustness for target recognition of intelligent excavator. It can identify multiple targets in complex conditions and has high recognition rate.

【Key words】 intelligent excavator; laser scanning; point cloud data; feature histogram; target recognition

DOI: 10.3969/j.issn.1000-3428.2017.01.051

0 概述

随着工程机械的智能化趋势, 挖掘机逐步实现智能化作业, 增加环境感知能力可有效提高作业效率和保障作业安全, 如辨识装卸车辆及其相对位置信息, 辨识影响作业安全的干扰。目前, 工程机械的环境感知主要为单目视觉^[1-2]或双目视觉^[3-4], 此类方法均利用电荷耦合器件(Charge Coupled Device, CCD)摄像头直接显示物体或通过物体形状特征识别目标类别, 在摄像头畸变、2个摄像头位置关系变化或环境光线较差的情况下会辨识失败。

近年来, 随着激光扫描技术的发展, 环境信息的三维点云获取愈加容易。相对于传统的摄像头视觉, 三维激光点云数据能更加清晰地感知作业环境, 且数字化程度高、速度快、精度高, 以 SICK 公司 LMS111 激光传感器为例, 最大测量距离为 20 m, 扫描频率为 50 Hz, 最大误差不超过最大测量距离的 2%~5%。因此, 使用激光传感器对环境进行感知更加准确稳健, 能适应复杂的工况。

激光点云目标识别技术的基本原理是通过比较待识别点云与点云模型的相似性来识别目标物体。文献[5]通过估算点云局部几何距离分布来识别点

基金项目: 国家“十二五”科技支撑计划项目(2013BAF07B02)。

作者简介: 朱建新(1965—), 男, 教授、博士、博士生导师, 主研方向为目标识别、机电一体化; 沈东羽, 硕士; 吴 钊, 工程师、博士。

收稿日期: 2016-01-13 修回日期: 2016-02-25 E-mail: zhujx@sunward.com.cn

云模型,该算法对激光扫描的距离要求较高,不同的扫描距离会直接影响识别成功率。文献[6-7]基于网络数据及域自适应性对扫描得到的点云数据进行目标识别,基于网络数据可以有效减少点云训练模型库数量及提高识别率,但不能在离线状态下进行目标识别。文献[8]利用离散矩阵计算点云形状特征描述子,该方法具有较高的识别率,但算法运算效率偏低。文献[9-10]通过提取点云模型表面特征向量以及视点信息,建立点云连续特征描述子,初步实现机器人对不同位姿目标的识别。本文针对挖掘机作业工况,提出一种点云特征直方图的目标识别方法,通过聚类分离算法获得单个识别目标,并用 k 最近邻(k Nearest Neighbor, kNN) 算法计算获得 k 近邻模型相似度来识别目标。实验中选取多个目标物体,在不同位置进行目标识别。

1 智能挖掘机目标识别方法设计

挖掘机正常工况通常为挖土和回转卸土,因此,本文利用回转操作对工作场景进行实时扫描以获得包含工况环境的点云数据,然后由安装在挖掘机上的工控机通过识别算法进行实时识别。以山河自主研发的 SWE230 中型挖掘机为实验平台,如图 1 所示,在挖掘机动臂两侧分别安装 2 个激光传感器,以便实现双向环境目标识别。采用德国 SICK 公司的 LMS111 室外型激光传感器作为点云获取装置,扫描角度间隔为 0.5° ,扫描有效半径为 20 m,扫描频率为 50 Hz。



图 1 激光传感器安装图

1.1 点云坐标系建立

激光传感器返回扫描面上物体的距离数据及对应的扫描角度,由回转编码器返回扫描时对应的回转角度。建立坐标系如图 2 所示,过挖掘机回转中心交地面于原点 O ,挖掘机正前方为 Z 轴正方向,驾驶室左侧方向为 X 轴正方向,上方为 Y 轴正方向,建立 XYZ 三维坐标系。激光传感器扫描面垂直于 $X-Z$ 面并且朝向挖掘机正前方,挖掘机可绕 Y 轴作回转运动。




图 2 点云坐标系示意图

假设激光传感器安装时激光发射点在该 XYZ 坐标系中的坐标为 (x_0, y_0, z_0) ,则激光发射点与坐标系原点的连线在 $X-Z$ 平面的投影与 Z 轴正向的夹角为 $\alpha = \arctan(x_0/z_0)$ 。若激光传感器在某时刻扫描到某点对应的距离为 r ,扫描角为 θ ,挖掘机回转角度为 φ ,则该点在 XYZ 坐标系中对应的坐标为:

$$\begin{cases} x = r \cdot \sin(\theta) \cdot \sin(\varphi) + (\sqrt{x_0^2 + z_0^2}) \cdot \sin(\varphi + \alpha) \\ z = r \cdot \sin(\theta) \cdot \cos(\varphi) + (\sqrt{x_0^2 + z_0^2}) \cdot \cos(\varphi + \alpha) \\ y = r \cdot \cos(\theta) + y_0 \end{cases}$$

1.2 挖掘机转速影响分析

激光传感器自身以 50 Hz 的扫描频率垂直 $X-Y$ 面自动扫描,即完成一次完整平面扫描需要 0.02 s,且单扫描面各扫描点的扫描间隔为 0.5° ,一个扫描面包含 360 个扫描点,则每个点的扫描时间为 5.56×10^{-5} s, SWE230 挖掘机的最大回转速度是 13.4 r/m,即 $80.4^\circ/\text{s}$ 。因此,激光传感器扫描一个点,挖掘机转过的角度为 0.00447° ,扫描面水平偏差距离为:

$$\Delta d = \Delta\theta \times \pi/180 \times r \quad (1)$$

对于连续 2 点,真实点和理论点会有 Δd 水平偏移,如图 3(a) 所示,假设扫描一条垂直 $X-Y$ 平面的线段,该线长为 L ,激光扫描间隔 θ 为 0.5° ,则该线段覆盖的扫描点数量为:

$$n \approx L / (r \times 0.5 \times \pi/180) \quad (2)$$

现假设扫描距离为 $r = 10$ m,扫描垂直线段长度为 $L = 1$ m,则 $n = 11$, $\Delta d = 0.77$ mm,如图 3(b) 所示,由式(1)、式(2)得激光扫描该线段时覆盖的扫描点的起始点和终止点水平偏差为 $\Delta D = \Delta d \times n = 8.58$ mm,即该直线倾斜了 $\varphi = 0.491^\circ$ 。




图 3 挖掘机转速影响示意图

可见误差很小,并且,实际操作时以低回转速度的方式扫描,其产生的误差更小,对于后续数据处理可忽略不计。

2 原始点云数据预处理及聚类分离

2.1 原始数据预处理

通过激光传感器扫描获得的原始点云数据存在数据量大、密度不均匀、含有大量噪声点的特点^[11],会影响后续的聚类分离及点云特征直方图计算的准确性,并降低算法运行效率,因此,需先对数据进行预处理操作,主要步骤如下:

1) 采用空间网格法降噪滤波对点云数据进行下采样滤波以获得精简的均匀化点云数据。对三维空间进行网格划分,将点云空间看成微小空间三维立方体的集合,将位于微小立方体内所有的点以立方体区域中心点来表示,其余点全部剔除。取得实验中 5 组数据,网格取 1 cm × 1 cm × 1 cm。下采样滤波效果如表 1 所示。

表 1 空间网格法下采样降噪滤波效果统计

组号	原始点数	降噪滤波后点数	滤除比例/%
1	149 729	110 227	26.38
2	191 286	134 712	29.58
3	167 034	118 015	29.35
4	70 668	44 459	37.09
5	131 538	103 376	21.41

2) 挖掘机工况下的噪声点表现为明显离群点,即在物体边缘处散乱随机出现杂乱点,根据此特点,本文采用离群点降噪算法。基于 kd-tree 原理^[12-13]对点云数据建立点与点之间的拓扑关系,用于点的快速搜索。搜索点云数据中待判定点 k 邻域范围内的点,计算它们之间的平均欧式距离:

$$d_0 = \frac{\sum_{i=0}^k \sqrt{(x_i - x_0)^2 + (y_i - y_0)^2 + (z_i - z_0)^2}}{k} \quad (3)$$

设定阈值为所有点平均欧式距离的均值 μ ,平均欧式距离大于 μ 的点判定为离群点,即噪声点,予以去除;反之,则判定为非噪声点,予以保留。其中, k 若取值过小,会影响噪声点的去除效果;若取值过大,则会明显增加降噪处理时间。经实验, k 取 30 能在保证处理速度的同时获得很好的噪声点去除效果。滤波效果如图 4 所示,图 4(a) 为降噪滤波前的卡车点云,明显包含很多边缘离散点,图 4(b) 为降噪滤波后的卡车点云,离散点滤波效果明显。




图 4 卡车点云降噪滤波效果示意图

经空间网格法和离群点滤波后,点云得到明显改善,如图 5 所示,图 5(a) 为降噪滤波前的点云邻域平均欧式距离,明显呈散乱状态,存在很多噪声点,图 5(b) 为降噪滤波后的点云邻域平均欧式距离,点云整体较均匀。




图 5 基于空间网格法与离群点的点云降噪滤波效果

2.2 点云聚类分离

扫描获得的点云数据呈现多个聚类相组合的特点,不利于对多个目标的单独识别。本文采用欧式聚类分离算法分离出单个目标聚类。首先基于 kd-tree 建立点云各点拓扑关系,创建空集合 Q 。

- 1) 随机选取点云中的某点 $p_i(x_0, y_0, z_0)$ 。
- 2) 搜索其 r 半径内的点集 P ,将其中的所有点添加到集合 Q 中。
- 3) 对获得的所有邻域点 $p_k \in P$,搜索其 r 半径内的邻域点,判断其是否在集合 Q 内,若不在 Q 内,则添加到 Q 。
- 4) 对新加入 Q 中的邻域点重复步骤 3),直到 Q 中没有新添加的点为止。
- 5) 此时集合 Q 构成一个点云聚类,将该聚类从点云数据中删除。

重复步骤 1) ~ 步骤 5) 逐步提取所有点云聚类。

r 的取值会影响聚类分离的效果,若取值过大,提取的聚类会较大,则可能无法分辨相邻物体;若取值过小,则会使得分离得到的聚类不完整。经实验, r 取 20 能获得良好的提取效果。

图 6 为挖掘机单次作业回转扫描获得的某区域

环境三维点云图像。图 7 为经过点云聚类分离算法提取的单个聚类图像。



图 6 挖掘机单次回转作业下的环境三维点云图像




图 7 经过点云聚类分离算法提取单个聚类的示意图

3 聚类目标识别

3.1 点云特征直方图建立

点云特征直方图通过计算点与点之间的空间几何关系,构建数字化的直方图来描述其关系。如图 8 所示,假设点云空间中有 2 点 $p_i(x_i, y_i, z_i)$ 及 $p_j(x_j, y_j, z_j)$ 及其对应的由邻域最小二乘平面拟合法^[13-14]获得的法向量 $n_i(x_i, y_i, z_i)$ 及 $n_j(x_j, y_j, z_j)$ 。




图 8 点云特征直方图的坐标系示意图

以 p_i 点为原点建立相对坐标系 UVW , p_i, p_j 构成的向量 $p = (x_i - x_j, y_i - y_j, z_i - z_j)$, u, v, w 分别是坐标轴 U, V, W 的方向向量,则:


$$\begin{cases} u = n_i \\ v = u \times \frac{p}{\|p\|_2} \\ w = u \times v \end{cases} \quad (4)$$

根据建立的相对坐标系,点 p_i, p_j 及其法线 n_i, n_j 之间的关系可表述如下:


$$\begin{cases} f_1 = v \cdot n_j \\ f_2 = \|p\|_2 \\ f_3 = u \cdot \frac{p}{\|p\|_2} \\ f_4 = \arccos(n_i \cdot n_j) \end{cases} \quad (5)$$

其中 f_1 表示 n_j 与 v 的夹角的余弦值; f_2 表示点 p_i, p_j 之间的距离; f_3 表示向量 p 与 u 之间夹角的余弦值; f_4 表示 n_i, n_j 的夹角。因此,可以用 (f_1, f_2, f_3, f_4) 4 组值来表述 2 点之间的距离关系及 2 点的法向量之间的角度几何关系,将原本相关的 12 个参数减少到 4 个。

在获取点云空间中所有点 k 邻域内点的 4 种特征描述子后,将得到 4 种特征描述子的值域空间划分为 n 个子区间,并统计落在各个子区间的数目,即可得到一个描述该点云几何特征的特征直方图。对于某点云数据,其点云特征直方图是唯一确定的。图 9 分别是点云特征直方图算法获得的某卡车及家用车扫描结果点云特征直方图。



(a) 卡车扫描结果及其点云特征直方图



(b) 家用车扫描结果及其点云特征直方图




图 9 点云特征直方图

3.2 基于 kNN 的点云特征直方图近邻搜索

kNN 是数据匹配算法中最常用的方法之一^[14-15]。算法的核心思想是若某样本在特征空间中与 k 个最相邻样本中的大多数属于同一类别, 则该样本也属于此类别。

基于 kNN 的点云特征直方图近邻搜索的主要流程为:

- 1) 选用合适的数据结构存储训练模型及测试数据。本文设置为点云特征直方图的数据存储格式。
- 2) 设定参数 k 值的选取需要根据模型库中的模型数量及分布情况而定。
- 3) 遍历模型集, 计算当前模型与测试数据的距离(相似度), 距离越小说明相似度越高。
- 4) 根据相似度进行排序, 筛选出最邻近的模型集。根据最近的 k 个识别结果及对应的距离判定待测点云数据的种类。

4 实验及结果分析

本文模拟挖掘机工作环境进行实验, 其周围随机位置同时停放多个工况常见目标物体, 包括卸土用的装载卡车, 停放在作业范围内的面包车、轿车, 随机出现的工作人员。通过数据处理软件实时处理数据, 与模型库比对得到识别结果、目标方位及距离, 与真实停放情况对比得到识别准确度。使用 C++ 编程, 处理平台为 Core 2 Duo CPU 2.5 GHz。为验证结果的可靠性, 待识别物体分别停放在 50 个不同位置, 扫描获得点云数据, 共计获得 300 组不同物体及不同位置的数据。图 10 为某未知聚类识别结果。未知聚类为现场扫描并进行预处理及聚类分离获得的某未知聚类, 经点云特征直方图的识别算法及 kNN 搜索获得最接近的 4 个模型点云, 分别为图 10 中的识别模型 1 ~ 模型 4。




图 10 某未知聚类识别结果

表 2 为 kNN 算法获得的识别模型的 kNN 距离, 数值越小说明识别模型越相似。根据实验结果, 一般识别结果属于同一类别的模型的 kNN 距离不大于 50, 例如图 10 中的未知聚类与同类别模型的 kNN 距离最大为 40.93, 而与面包车模型的 kNN 距离为 234.15。根据近邻模型结果及 kNN 距离, 该点云聚类可识别为卡车。

表 2 kNN 距离统计

模型	kNN 距离
识别模型 1	12.64
识别模型 2	20.27
识别模型 3	30.82
识别模型 4	40.93
面包车模型	234.15

实验中针对各不同实验目标的识别结果统计如表 3 所示。根据实验内容及实验结果进行分析, 本文提出方法的整体识别成功率较高。由于模型库中卡车模型、面包车模型及轿车模型丰富且点云几何特征区别明显, 识别率达到 100%。斜放的卡车由于姿态的随机性, 识别率略有降低。而由于模型库中没有装货卡车模型, 有货卡车的识别依据模型库中的空卡车模型, 并且装货卡车的货物量存在随机性, 识别率也有所降低。工作人员由于目标较小且人物体型、姿态多样, 识别率有所降低。上述问题可通过完善模型库的方法进一步提高识别率。

表 3 识别结果统计

目标类别	总实验次数	成功识别次数	识别率/%	平均耗时/s
卡车(空)	50	50	100	1.92
卡车(斜放)	50	45	90	2.02
卡车(有货)	50	47	94	2.23
轿车	50	50	100	1.98
面包车	50	50	100	2.02
工作人员	50	46	92	1.87
合计	300	288	96	2.01

由表 3 可知, 当点云数据量增大时处理时间略有增加。本文采用的预处理方法及聚类分离方法有效地提高了运行效率, 识别程序平均耗时 2.01 s, 适用于挖掘机实时连续环境目标识别。与其他传统目标识别方法^[1-4]的统计结果相比, 点云特征直方图法在识别率及识别速度上具有明显优势。

5 结束语

针对挖掘机工况环境,提出一种基于点云特征直方图的环境目标辨识方法。该方法以点云中各点之间的向量为数学背景,通过将关键角度数据转换为直方图数据,以及将目标识别问题转换为模型库数据相似度匹配问题,从而获得高精度识别结果,为挖掘机辅助作业提供新的解决方案,有利于推进智能挖掘机作业效率及作业安全性。

随着激光技术的不断发展以及新的环境信息获取工具的出现,采用新的方法感知工况作业环境是必然的发展趋势。本文采用提出的方法在挖掘机实际工况下进行实验,并针对多个物体在不同位置获取多组数据,在识别准确度、识别速度、程序自动化程度上都达到较高水准,丰富了挖掘机利用激光传感器进行环境目标辨识的经验,且具有很强的可移植性,可在其他工程机械上使用。下一步工作将在目标识别实验中将加入轨迹规划功能,以实现挖掘机的自主挖掘及避障功能。

参考文献

- [1] 王福斌,王福平,董永,等. 挖掘机机器人视觉目标定位[J]. 计算机测量与控制, 2015, 23(4): 1362-1363.
- [2] 杨丽. 智能化挖掘机自主作业过程目标识别及定位技术研究[D]. 长春: 吉林大学, 2004.
- [3] 肖婷,文怀兴,夏田. 基于双目识别技术的挖掘机智能化控制系统[J]. 工程机械, 2007, 38(3): 4-7.
- [4] 王福斌,刘杰,陈至坤,等. 小松液压挖掘机机器人化改造[J]. 机床与液压, 2010, 38(22): 52-54.
- [5] Mahmoudi M, Sapiro G. Three-dimensional Point Cloud Recognition via Distributions of Geometric Distances[J]. Graphical Models, 2008, 71(1): 22-31.
- [6] Lai K, Fox D. Object Recognition in 3D Point Clouds Using Web Data and Domain Adaptation[J]. The International Journal of Robotics Research, 2010, 29(8): 1019-1037.
- [7] Drost B, Ulrich M, Navab N, et al. Model Globally, Match Locally: Efficient and Robust 3D Object Recognition[C]//Proceedings of 2010 IEEE Conference on Computer Vision and Pattern Recognition. Washington D. C., USA: IEEE Press, 2010: 998-1005.
- [8] Zhong Y. Intrinsic Shape Signatures: A Shape Descriptor for 3D Object Recognition[C]//Proceedings of the 12th International Conference on Computer Vision Workshops. Washington D. C., USA: IEEE Press, 2009: 689-696.
- [9] Rusu R B, Blodow N, Marton Z C, et al. Aligning Point Cloud Views Using Persistent Feature Histograms[C]//Proceedings of IEEE/RSJ International Conference on Intelligent Robots and Systems. Washington D. C., USA: IEEE Press, 2008: 3384-3391.
- [10] Rusu R B, Bradski G, Thibaux R, et al. Fast 3d Recognition and Pose Using the Viewpoint Feature Histogram[C]//Proceedings of 2010 IEEE/RSJ International Conference on Intelligent Robots and Systems. Washington D. C., USA: IEEE Press, 2010: 2155-2162.
- [11] 戴静兰. 海量点云预处理算法研究[D]. 杭州: 浙江大学, 2006.
- [12] Shekhar A, Sharma T, Srivastava D K. Effectiveness of Kd-tree in Ray Tracing of Dynamic Point Clouds[J]. Networking and Communication Engineering, 2015, 7(4): 133-137.
- [13] Hubo E, Mertens T, Haber T, et al. The Quantized kd-Tree: Efficient Ray Tracing of Compressed Point Clouds[C]//Proceedings of Symposium on Interactive Ray Tracing. Washington D. C., USA: IEEE Press, 2006: 105-113.
- [14] Connor M, Kumar P. Fast Construction of k-nearest Neighbor Graphs for Point Clouds[J]. IEEE Transactions on Visualization and Computer Graphics, 2010, 16(4): 599-608.
- [15] Weinberger K Q, Saul L K. Distance Metric Learning for Large Margin Nearest Neighbor Classification[J]. Journal of Machine Learning Research, 2009, 10(1): 207-244.

编辑 陆燕菲